Instituto Politécnico Nacional

Escuela Superior de Cómputo

Algoritmos Bioinspirados

Práctica 1.
Algoritmo genético con codificación binaria

Bustillos Cruz Jonatan

Gutiérrez Sánchez Angélica

Grupo 5BM2

Índice

1. Introducción **2**
1.1. Objetivos . . . 2
1.1.1. Objetivo general . . . 2
1.1.2. Objetivos específicos . . . 2
1.2. Organización del documento . . . 2

2. Marco Teórico **3**
2.1. Algoritmos genéticos . . . 3
2.2. Nonogramas . . . 3
2.3. Gráficas de convergencia . . . 3

3. Implementación de algoritmo genético con codificación binaria **4**
3.1. Selección de padres: Torneo binario estocástico . . . 4
3.2. Recombinación: Cruza de n puntos y cruza uniforme . . . 4
3.3. Mutación . . . 4
3.4. Selección de sobrevivientes: Elitismo . . . 5
3.5. Diagrama de flujo . . . 5

4. Pruebas y resultados **7**
4.1. Configuraciones . . . 7
4.2. Resultados nonograma prueba 1 . . . 8
4.3. Resultados nonograma prueba 2 . . . 9

5. Análisis de artículo científico **11**

6. Conclusiones **12**
6.1. Conclusiones de Angélica . . . 12
6.2. Conclusiones de Jonatan . . . 13

7. Referencias **14**

1. Introducción

En este documento se exploran los principios fundamentales de los algoritmos genéticos y su aplicación en la resolución de problemas de optimización. El enfoque principal de la práctica es la implementación de un algoritmo genético utilizando codificación binaria para resolver el problema de optimización del nonograma. A través de esta práctica, se examinan los componentes esenciales de los algoritmos genéticos, como los mecanismos de selección, cruce y mutación, y su impacto en la evolución de las soluciones. Además, se analizará el proceso de convergencia del algoritmo, utilizando gráficas para ilustrar la mejora en las soluciones a lo largo de las generaciones.

1.1. Objetivos

1.1.1. Objetivo general

Comprender el funcionamiento básico de los algoritmos genéticos para resolver problemas de optimización con codificación binaria.

1.1.2. Objetivos específicos

- Entender el funcionamiento de los pasos que sigue un algoritmo genético.
- Estudiar diferentes estrategias de operadores de selección, cruz y mutación.
- Implementar un algoritmo genético para buscar soluciones de un nonograma (puzzle).

1.2. Organización del documento

Este documento se organiza de la siguiente manera: En el capítulo 1 se presenta una introducción a los objetivos de la práctica, donde se definen tanto el objetivo general como los objetivos específicos para comprender el funcionamiento básico de los algoritmos genéticos y su aplicación en la resolución de problemas de optimización con codificación binaria.

En el capítulo 2 se aborda el marco teórico relacionado con los algoritmos genéticos, su funcionamiento y su aplicación a problemas de optimización. Además, se describe el problema del nonograma, así como las gráficas de convergencia utilizadas para evaluar el rendimiento del algoritmo en la búsqueda de soluciones óptimas.

En el capítulo 3, se detallan las estrategias implementadas en el algoritmo genético, incluyendo la selección de padres mediante torneo binario estocástico, los métodos de recombinación como la cruza de n puntos y la cruza uniforme, la mutación, y la selección de sobrevivientes con elitismo. Este capítulo también incluye un diagrama de flujo que ilustra el funcionamiento global del algoritmo.

En el capítulo 4 se presentan los resultados obtenidos a partir de la implementación del algoritmo genético para la resolución del problema del nonograma. Se detallan las métricas utilizadas para evaluar el rendimiento del algoritmo así como las gráficas de convergencia que ilustran el progreso del algoritmo a lo largo de las generaciones, permitiendo observar cómo evoluciona la solución hacia una respuesta óptima o cercana a la óptima.

En el capítulo 5 se realiza un análisis detallado de un artículo científico relacionado con la resolución de nonogramas mediante algoritmos genéticos. Este análisis se lleva a cabo a partir de la respuesta a varias preguntas clave que abordan diferentes aspectos del enfoque propuesto en el artículo.

Finalmente en el capítulo 6 se presentan las conclusiones derivadas de la práctica, resumiendo los principales hallazgos y aprendizajes obtenidos a lo largo del desarrollo y análisis del algoritmo genético aplicado al problema del nonograma.

2. Marco Teórico

2.1. Algoritmos genéticos

Los algoritmos genéticos (GA por sus siglas en inglés) son meta-heurísticas de búsqueda que imitan el proceso de evolución natural, utilizando conceptos como la Selección Natural y la Herencia Genética introducidos inicialmente por las teorías de Charles Darwin.
Los algoritmo genéticos fueron desarrollados originalmente por John Holland en 1975, donde las posibles soluciones de un problema de optimización son representadas por individuos que conforman una población. Cada individuo se codifica a través de una cadena conocida como cromosoma, la cual se compone de genes, estos representarán las variables de decisión del problema.

La evaluación de cada individuo en la función objetivo indicará la aptitud de este para sobrevivir de una generación a otra. Por otro lado, los indivividuos de una población pueden reproducirse, combinando su información genética (procedimiento de cruza o recombinación) para crear descendientes (nuevas soluciones). Las soluciones hijas pueden tener variaciones en su cromosoma a través de un procedimiento conocido como mutación. Finalmente, existe un proceso de selección de sobrevivientes donde se favorecerá la sobrevivencia de los individuos mas aptos de la población, es decir, aquellas soluciones que optimicen en mayor medida la función objetivo.

2.2. Nonogramas

Un nonograma es un tipo de rompecabezas lógico que consiste en rellenar celdas dentro de una cuadrícula para revelar una imagen oculta.

El objetivo de resolver este tipo de rompecabezas es decubrir un patrón oculto basado en los números que aparecen en los bordes de la cuadrícula. Estos números indican cuántas celdas consecutivas deben rellenarse en cada fila y columna. Los jugadores deeben deducir qué celdas rellenar y cuáles dejar vacías, usando lógica para resolver el puzzle.

Entre las reglas básicas se tiene:

- Los números en cada fila o clumna muestran el tamaño de los bloques consecutivos de celdas que deben der rellenadas.
- Si hay mas de un número, indica que hay varios bloques, con al menos una celda vacía.
- El desafío es combinar la información de las filas y columnas para completar el rompecabezas correctamente.
- Cuando el puzzle se resuelve correctamente, el resultado es una imágen (pixelada), que pueden ser figuras simples hasta escenas complejas.

2.3. Gráficas de convergencia

Las gráficas de convergencia en la solución de un nonograma con un algoritmo genético muestran cómo el rendimiento del algoritmo mejora con el tiempo a medida que evoluciona la población de soluciones, siendo fundamentales para evaluar su eficiencia y efectividad en la búsqueda de soluciones óptimas.

Estas gráficas suelen representar la función objetivo en el eje y y el número de generaciones en el eje x. Algunas variantes incluyen el promedio de la función objetivo por generación, que muestra la mejora promedio de la población con el tiempo; el mejor individuo por generación, que indica si el algoritmo encuentra soluciones óptimas progresivamente; y la desviación estándar de la función objetivo, que refleja la variabilidad en la aptitud de los individuos, permitiendo evaluar si la población está convergiendo a una única solución o si mantiene diversidad en sus soluciones.

3. Implementación de algoritmo genético con codificación binaria

3.1. Selección de padres: Torneo binario estocástico

Para la estrategia de selección de padres se utilizó el torneo binario estocástico. Este es una variante del torneo binario en la que se introduce un elemento de aleatoriedad en la selección de individuos. En este enfoque, dos o más individuos compiten entre sí, pero la selección no es determinística como en el torneo clásico, sino que se realiza de manera probabilística, basándose en las aptitudes relativas de los individuos participantes.

Se escogió este método porque permite mantener la diversidad genética en la población, evitando la convergencia prematura a soluciones subóptimas. Dado que el problema del nonograma es una tarea de optimización combinatoria con restricciones específicas, es fundamental evitar que el algoritmo genético quede atrapado en óptimos locales. La selección estocástica permite que individuos con soluciones parcialmente correctas, pero con potencial de mejora, sigan participando en la evolución de la población.

Este balance entre explotación de buenas soluciones y exploración de nuevas configuraciones del espacio de búsqueda contribuye a una mayor robustez del algoritmo. Al permitir cierta variabilidad en la selección, se mejora la eficiencia del proceso de optimización, aumentando las posibilidades de encontrar soluciones óptimas.

3.2. Recombinación: Cruza de n puntos y cruza uniforme

Con respecto a la estrategia de recombinación, se emplearon dos enfoques: cruza de n puntos y cruza uniforme. La cruza de n puntos es una generalización de los métodos de cruza de un punto y dos puntos: se seleccionan n puntos de corte en los cromosomas de los padres, y los segmentos definidos por estos puntos se intercambian para generar nuevos individuos; se eligió este método debido a que permite preservar ciertas estructuras parciales de soluciones viables, facilitando la transmisión de patrones correctos de una generación a otra, crucial en la resolución de un nonograma, donde la correcta disposición de bloques en las filas y columnas define la factibilidad de la solución.

Por otro lado, la cruza uniforme intercambia genes de los padres de manera aleatoria según una probabilidad determinada. Este enfoque se escogió porque promueve una mayor diversidad en la población al evitar la preservación forzada de segmentos largos de genes de un solo progenitor. En el contexto del nonograma, esto permite explorar configuraciones alternativas sin depender excesivamente de patrones preexistentes, reduciendo el riesgo de que el algoritmo quede atrapado en soluciones parciales incorrectas.

3.3. Mutación

Se optó por la mutación como parte del algoritmo genético para solucionar el nonograma debido a su capacidad para introducir variabilidad aleatoria en la población de soluciones, evitando la convergencia prematura y mejorando la exploración del espacio de soluciones. Su principal función es alterar algunos genes de un individuo de manera aleatoria, lo que permite al algoritmo escapar de óptimos locales y explorar nuevas configuraciones.

Se escogió este mecanismo porque en la resolución de un nonograma es común que la recombinación por sí sola no sea suficiente para corregir errores en la configuración de los individuos. Dado que un nonograma es un problema de optimización combinatoria con restricciones estrictas, la mutación ayuda a corregir patrones incorrectos y a generar nuevas estructuras de solución viables.

Además, al aplicar mutación con una probabilidad controlada, se garantiza un equilibrio entre la explotación de soluciones parciales correctas y la exploración de configuraciones alternativas. Esto permite que el algoritmo mantenga la diversidad en la población y tenga mayores probabilidades de encontrar una solución óptima sin quedar atrapado en estados subóptimos.

3.4. Selección de sobrevivientes: Elitismo

Se optó por elitismo para asegurar que la calidad de la población no disminuya a medida que avanza el algoritmo, mejorando la convergencia hacia soluciones óptimas y evitando la pérdida de individuos prometedores.

En la resolución de un nonograma, es crucial mantener patrones correctos que ya han sido encontrados en generaciones previas. Sin elitismo, es posible que la recombinación y la mutación eliminen configuraciones parciales que cumplen con las restricciones del problema, lo que dificultaría el progreso hacia una solución válida. Al preservar los mejores individuos, el algoritmo puede enfocarse en refinar y mejorar soluciones viables en lugar de redescubrirlas constantemente.

Además, el elitismo ayuda a equilibrar la exploración y explotación del espacio de soluciones. Mientras que otros operadores genéticos, como la mutación, introducen variabilidad, el elitismo garantiza que el algoritmo no pierda el conocimiento adquirido en generaciones anteriores, aumentando así la eficiencia en la búsqueda de la solución óptima para el nonograma.

3.5. Diagrama de flujo

En la figura 1 se presenta el diagrama de flujo del algoritmo genético implementado. Se ha realizado conforme al ejemplo proporcionado. Al comienzo se envían los parámetros que modifican el algoritmo: el tamaño de población y de cromosoma, el porcentaje de cruza, mutación y selección (porcentaje para seleccionar mejor en el torneo); el criterio de paro por similaridad, es decir, qué tan similares puede ser el mejor del peor (0 son iguales); la probabilidad de seleción en el torneo binario estocástico (probabilístico), es decir, con qué probabilidad se selecciona al mejor individuo en el torneo; un intervalo de muestreo para la impresión de control (un múltiplo del número de generaciones proporcionado); tipo de cruza (uniforme o n puntos), finalizando con la *seed* y el número de ejecuciones para la versión optimizada para la resolución del nonograma de prueba 2. Pasando luego a la creación de la población que será totalmente aleatoria.

A continuación se ingresa en un bucle, que sólo puede terminar cuando el criterio de paro se cumple, tanto por haber encontrado la solución o por cumplir el criterio de similaridad antes descrito. Se definen las parejas por medio de torneo binario estocástico, siendo **flip** la función que determina la elección final. Luego, una vez que se tienen los padres seleccionados se usa la función **creaHijos** para la generación de los descendientes, se realiza su mutación y el cálculo de la aptitud. A continuación, se une la población padres e hijos y se procede a seleccionar a los mejores con la función **elitismo** (que limita la población a los mejores), luego se obtienen los datos cruciales de esta generación: mejor aptitud, peor y promedio. Finalmente, se revisa el criterio de paro y si se cumple, se termina el programa, si no, continua en la siguiente generación.

Cuando se termina de ejecutar el bucle, sólo queda imprimir los resultados y retornar la mejor aptitud para la subsiguientes estadísticas.

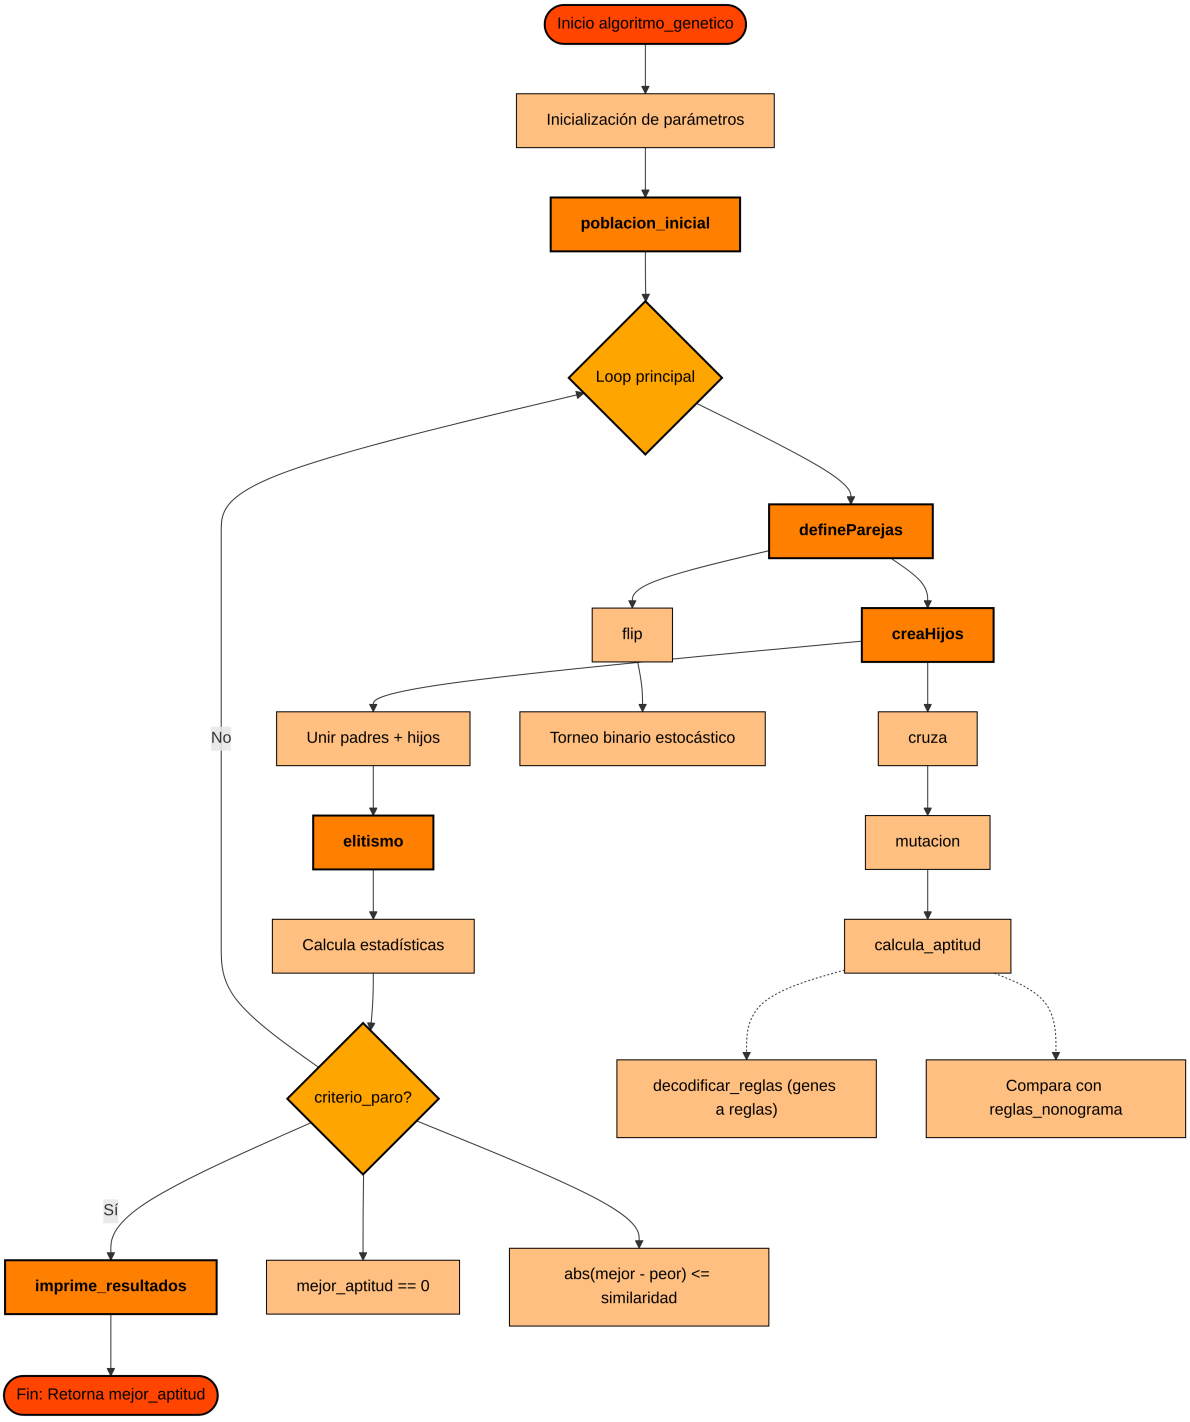

Figura 1: Diagrama de flujo del algoritmo genético

4. Pruebas y resultados

En esta sección, se presentan los resultados de las pruebas más efectivas, realizadas para resolver nonogramas utilizando el algoritmo bioinspirado con diferentes configuraciones.

En primer lugar, se llevaron a cabo pruebas unitarias para analizar la naturaleza de los cambios generados por la variación de los diferentes parámetros. En segundo lugar, se identificaron las mejores configuraciones y aquí se muestran solo las tres mejores encontradas.

4.1. Configuraciones

Las configuraciones son conjuntos de parámetros escogidos principalmente con la experimentación. Se obtuvieron probando con el nonograma de prueba 1, buscando evitar la convergencia prematura. El principal aporte de la experimentación fue encontrar que, a menor mutación, por el orden del 1 u 2 por ciento, se obtenían mejores resultados, así mismo que el cambio de cruza uniforme sobre la cruza de n puntos y el aumento de la población. Siendo las demás configuraciones menos decisivas para la mejora el algoritmo, pero que aportaban su granito de arena.

Cabe aclarar que dependiendo del tipo de nonograma, el tamaño del cromosoma varía, siendo de 100 para el primero y de 625 para el segundo.

A continuación se muestran las configuraciones en orden descendente.

1. **Mejor**
   - Tamaño de la población: 500
   - Porcentaje de cruza: 90.0 %
   - Porcentaje de mutación: 2.0 %
   - E (nivel de similitud entre el peor y mejor): 0
   - Elección del mejor en el torneo: 70 %
   - Tipo de cruza: uniforme
2. **Intermedio**
   - Tamaño de la población: 400
   - Porcentaje de cruza: 87.0 %
   - Porcentaje de mutación: 1.618 %
   - E (nivel de similitud entre el peor y mejor): 0
   - Elección del mejor en el torneo: 70 %
   - Tipo de cruza: n_puntos
   - Número de puntos de corte: 38
3. **Bajo**
   - Tamaño de la población: 300
   - Porcentaje de cruza: 60.0 %
   - Porcentaje de mutación: 1.0 %
   - E (nivel de similitud entre el peor y mejor): 0

- Elección del mejor en el torneo: 70 %
- Tipo de cruza: n_puntos
- Número de puntos de corte: 6

4.2. Resultados nonograma prueba 1

Para este nonograma aunque relativamente simple por ser uno de 10x10, tiene un espacio de búsqueda:

$$2^{100} = 1267650600228229401496703205376 \tag{1}$$

Justificando así la utilización de un algoritmo genético para atajar el problema.

Entrando en materia, con la mejor configuración se obtuvieron resultados excepcionales (Tabla 1), dando un 100 % de éxitos en la resolución del problema, nótese que esto fue con un tipo de cruza uniforme, obteniendo resultados muy superiores a los obtenidos con otras configuraciones. A continuación, ejemplos de los resultados obtenidos.

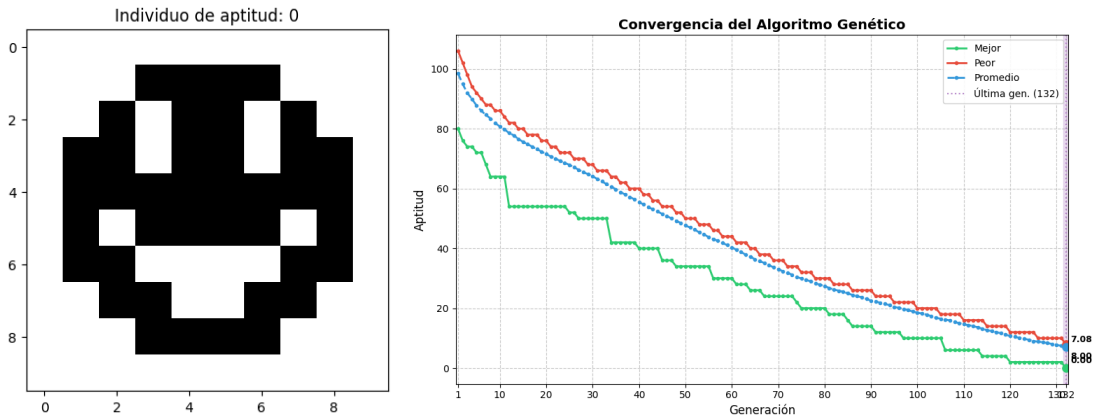

(a) Individuo (b) Gráfica

Figura 2: Resultados con la **configuración 1** en el nonograma de prueba 1 con *seed* 2.

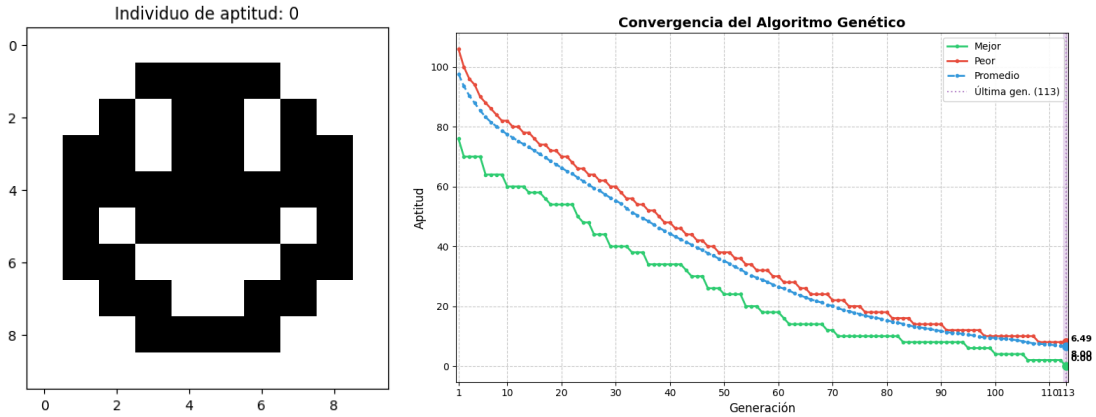

(a) Individuo (b) Gráfica

Figura 3: Resultados con la **configuración 2** en el nonograma de prueba 1 con *seed* 2.

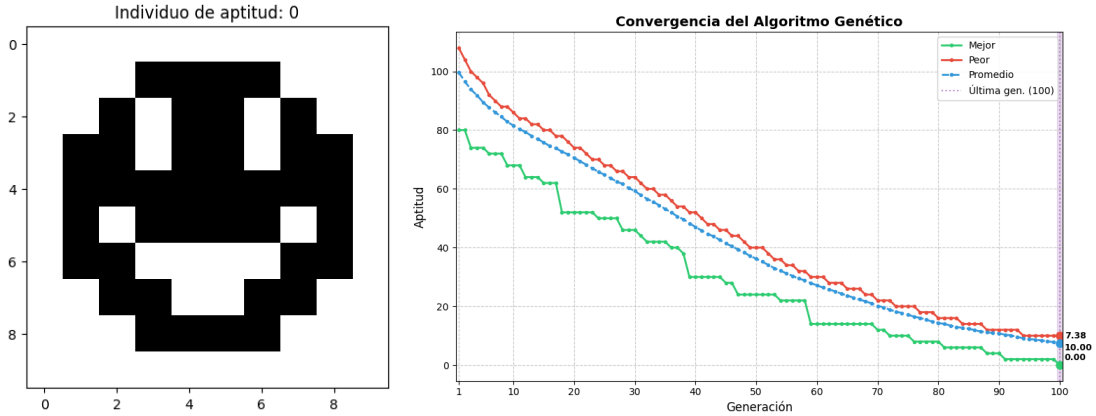

(a) Individuo (b) Gráfica

Figura 4: Resultados con la **configuración 3** en el nonograma de prueba 1 con *seed* 2.

Conf	Porcentaje de éxitos	Promedio función objetivo	Desviación estándar	Mínimo de la función	Máximo de la función
1	100 %	0	0.0	0	0
2	95 %	0.1	0.436	0	2
3	75 %	0.5	0.866	0	2

Tabla 1: Tabla de resultados del nonograma de prueba 1

Aunque en los resultados (figuras 2, 3, 4) no parecen tener mucha diferencia, pero en general se ha visto que la cruza de n puntos tiende a cerrar la brecha entre el mejor y el peor antes de tiempo. Con cruza uniforme, población adicional, mutación y más cruza, se ha podido lograr un rendimiento óptimo evitando que converja prematuramente (tabla 1).

4.3. Resultados nonograma prueba 2

Para este nonograma, la complegidad de su espacio de búsqueda de:

$$2^{625} \tag{2}$$

Tiene un espacio de búsqueda tan vasto, que se requieren técnicas adicionales o un tiempo muy grande para alcanzar un resultado óptimo. Con un día de ejecución en varias semillas, se pudo obtener un resultado más o menos aceptable (figura 5).

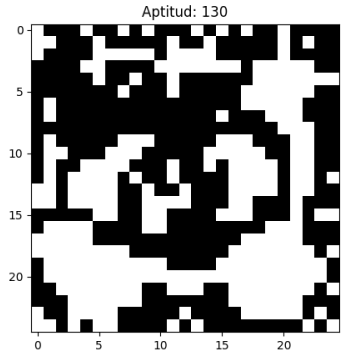

(a) Individuo

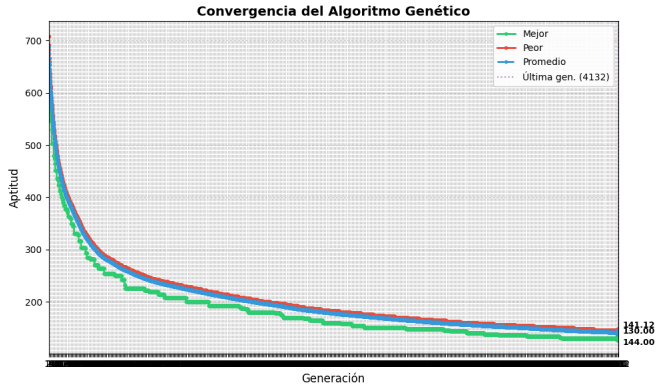

(b) Gráfica

Figura 5: Resultados con la **configuración 2** en el nonograma de prueba 2 con *seed* 19 y 15 de la diferencia entre el peor y el mejor.

En general, los resultados no fuero óptimos, además de que se tardaba mucho tiempo en completar las ejecuciones. Por tanto, la experimentación se realizó principalmente en el nonograma de prueba 1. Además, debido al tiempo de las ejecuciones, sólo alcanzó para obtener resultados para las 2 primeras configuraciones. Por tanto, para no hacer una comparativa injusta con la tercera, ya que las dos fueron normalizadas a una diferencia de 15 entre el mejor y el peor, se colocan sólo las dos primeras.

Conf	**Porcentaje de éxitos**	**Promedio función objetivo**	**Desviación estándar**	**Mínimo de la función**	**Máximo de la función**
1	0 %	178.9	22.2	148	246
2	0 %	159.45	22.9	130	214
3	-	-	-	-	-

Tabla 2: Tabla de resultados del nonograma de prueba 2

Se puede apreciar (tabla 2) que la configuración 2 con n puntos fue mucho más efectiva, esto debido a que se implementó con 38 puntos de cruza. Lo cual mejoró mucho su rendimiento.

5. Análisis de artículo científico

1. **¿Cuáles fueron las implementaciones que emplearon para solucionar el problema?**

   Por un lado, se implementó la codificación condensada, una técnica más eficiente que la codificación binaria tradicional, donde cada celda del nonograma se representa con un 0 o un 1. En lugar de almacenar el estado de cada celda de la cuadrícula, la codificación condensada guarda únicamente la información esencial de cada fila: la cantidad de grupos de celdas negras y su distribución. De este modo, en lugar de representar cada celda de forma individual, se optimiza el almacenamiento y se reduce significativamente el tamaño del espacio de búsqueda, lo que mejora la eficiencia del algoritmo y acelera la convergencia hacia una solución válida.

   También se implementó una función objetivo mejorada, en donde no solo compara la cantidad de celdas negras en cada columna con la solución deseada, sino que también considera su orden. En trabajos anteriores, la evaluación solo contaba el número total de 1s (celdas negras) sin importar su posición, lo que generaba errores en la selección de soluciones potenciales.

   En un Algoritmo Genético estándar, la operación de cruce intercambia genes individuales entre dos soluciones. Sin embargo, en el TBGA, se implementó un cruce basado en filas completas, lo que evita que se generen soluciones no factibles. Al intercambiar filas enteras en lugar de genes individuales, se garantiza que cada fila siga respetando las restricciones impuestas por el problema.

   Además en un AG tradicional, la mutación cambia un bit aleatoriamente de 0 a 1 o viceversa. En este trabajo, la mutación fue modificada para operar dentro de las filas, asegurando que los cambios en la solución no rompan las restricciones del nonograma. En lugar de simplemente cambiar un 0 a un 1 en una ubicación aleatoria, se reubican los valores dentro de la fila sin generar agrupaciones incorrectas.

   Para la operación de cruce se integró el método Taguchi para optimizar la generación de descendencia. Se utilizó un arreglo ortogonal de dos niveles, tratando cada fila del nonograma como un factor con dos posibles valores. A través de experimentos diseñados con esta metodología, se identificaron las mejores combinaciones de genes, lo que permitió generar soluciones con mayor probabilidad de ser óptimas, acelerando así la convergencia del algoritmo hacia la solución correcta del nonograma.

2. **Explique de qué trata el método de Taguchi**

   Es una técnica de optimización cuyo objetivo principal es reducir la variabilidad en los resultados sin necesidad de eliminar las causas de variación, lo que permite obtener soluciones más robustas y estables.

   Los dos conceptos principales de éste método son la relación señal-ruido (S/N) y los alrreglos ortogonales; la primera es una métrica que evalúa la calidad de una solución en presencia de variabilidad, se busca maximizar la señal útil y minimizar el ruido, asegurando que los resultados sean confiables y consistentes; los segundos son estructuras matemáticas que permiten evaluar múltiples variables con un número reducido de experimentos; en lugar de analizar todas las combinaciones posibles de parámetros (lo que sería computacionalmente costoso), el método Taguchi selecciona un subconjunto representativo de combinaciones, optimizando el proceso de búsqueda de soluciones.

3. **¿Cuál es la diferencia con las funciones objetivo empleadas en el artículo?**

   En estudios previos, como el de Salcedo-Sanz et al. (2007), la función objetivo utilizada para evaluar soluciones en los nonogramas únicamente comparaba el número total de celdas negras (1s) y espacios en filas y columnas, sin tomar en cuenta su orden o distribución dentro de la cuadrícula. El problema de esta función es que se pueden generar soluciones incorrectas que tienen la cantidad correcta de celdas negras, pero en posiciones equivocadas, es decir que, el algoritmo podría considerar incorrectamente algunas soluciones como óptimas cuando, en realidad, no lo son.

   En cambio, la función objetivo mejorada en el TBGA introduce un cálculo más preciso: primero evalúa no solo el número de 1s en cada columna, sino también su orden y distribución, además minimiza la diferencia entre la cantidad deseada y la cantidad real de celdas negras en cada columna; y evita que soluciones incorrectas sean consideradas óptimas, lo que ayuda al algoritmo a converger hacia la respuesta correcta.

4. **De acuerdo con las pruebas, ¿cuáles fueron las dificultades que enfrentaron los autores para encontrar las soluciones al problema?**

   Los autores identificaron varios desafíos al tratar de resolver los nonogramas japoneses mediante algoritmos genéticos. Estas dificultades afectaban la eficiencia y precisión del algoritmo, lo que llevó a la necesidad de desarrollar una versión mejorada con el método Taguchi:

   - El tamaño del espacio de búsqueda dificultaba que el AG encontrara soluciones correctas en un tiempo razonable, ya que exploraba una cantidad enorme de posibilidades sin una dirección clara hacia la solución óptima.
   - La convergencia se veía afectada porque el GA tenía dificultades para reducir el espacio de búsqueda de forma eficiente, ya que no tomaba en cuenta la estructura del nonograma de manera efectiva.
   - El AG no cumplían con los patrones esperados y tenían que ser descartadas, lo que reducía la eficiencia del proceso de búsqueda, dicho problema hacía que el algoritmo gastara tiempo computacional evaluando soluciones inválidas, en lugar de centrarse en aquellas que realmente podrían resolver el nonograma.
   - El AG favorecía soluciones incorrectas, lo que afectaba su capacidad para mejorar de manera efectiva a lo largo de las generaciones. Además, las funciones de aptitud tradicionales no proporcionaban suficiente información para guiar al algoritmo genético hacia la solución correcta, lo que contribuía aún más a su baja eficiencia.

6. Conclusiones

6.1. Conclusiones de Angélica

En conclusión, se puede decir que el algoritmo genético desarrollado mostró un desempeño efectivo en la resolución de nonogramas pequeños, como el de 10x10, pero su estructura básica no fue suficiente para abordar nonogramas más grandes, como el de 25x25. A medida que la complejidad del problema aumentó, el algoritmo tuvo dificultades para encontrar soluciones óptimas, evidenciando la necesidad de mejoras en la representación de las soluciones y en la aplicación de operadores genéticos más avanzados.

Para lograr una mayor precisión en la resolución de nonogramas grandes, es conveniente optimizar la función de aptitud, mejorar los operadores genéticos y considerar enfoques híbridos que combinen estrategias

evolutivas con heurísticas especializadas. Con estas mejoras, el algoritmo podría ampliar su capacidad para resolver problemas de mayor tamaño de manera más efectiva.

6.2. Conclusiones de Jonatan

Para terminar, se concluye se ha aprendido a implementar con éxito un algoritmo genético para espacios de búsqueda relativamente reducidos. Dado que es la introducción a estos algoritmos, los resultados pueden mejorarse, quizás aplicando una mejor optimización del código, así como una preparación más adecuada de las ejecuciones de mayor envergadura.

Es preciso mencionar que la selección de parámetros por medio de experimentación provoca que estos algoritmos tengan un remanente de diversidad enorme que recuerda a la propia vida del que se inspiran.

7. Referencias

- Carlos A. Coello Coello, *Algoritmos Genéticos y sus Aplicaciones*, CINVESTAV-IPN, México, D.F., 2023. [En línea]. Disponible en: `https://delta.cs.cinvestav.mx/~ccoello/compevol/genetico.pdf?`
- Carlos A. Coello Coello, *Introducción a la Computación Evolutiva (Notas de Curso)*, CINVESTAV-IPN, México, D.F., 2023. [En línea]. Disponible en: `https://delta.cs.cinvestav.mx/~ccoello/compevol/apuntes.pdf?`
- Tsai, *Solving Japanese nonograms by Taguchi-based genetic algorithm*, Applied Intelligence, vol. 37, no. 3, pp. 405–419, 2012.